

Отчёт ИТ vs бизнес-требования

Отчёт о нагрузочном тестировании vs бизнес-требования

Поле	Значение
Дата прогона	2026-07-16 (UTC 15:49–16:20)
Окружение	test-stand VPS 45.91.236.105 (CPU, 2 vCPU / 3.8 GiB RAM)
Цель API	http://naming-check-backend:8000 (k6 на стенде)
Инструмент	k6, профили smoke / baseline / stress
Сценарии	mixed S1–S4 (веса 60% / 25% / 10% / 5%)
Сырые логи	smoke.log, baseline.log, stress.log, meta.txt
Источники требований	Documentation/requirements.md, MoSCoW M12, quality_plan.md Gate 2, docs/performance/load_testing_goals.md §4–§6

1. Итоговый вердикт

Продуктовым SLA из ТЗ формально не закрываем: они относятся к полному пайплайну (full query < 2 мин, Stage 1 P95/P99, Stage 2 ≤ 120 с), которого в MVP-прогоне k6 нет.

По операционным MVP SLO на CPU-стенде:

Профиль	Вердикт	Комментарий
Smoke (1 VU, 30 с)	PASS	error 0%, p95 ≈ 0.80 с
Baseline (1 VU, 10 мин)	PASS	error 0%, p95 ≈ 0.73 с, ~0.8 iter/s
Stress (ramp 5→30 VU, 20 мин)	FAIL	error 26.8% , checks 74.6%, p95 ≈ 2.40 с

Главный гар: под stress падает visual-model-service (502/503 на logo search / preview). Текст (S1) и health (S4) держат нагрузку на 100%.

2. Соответствие продуктовым SLA (ТЗ / Gate 2)

Требование	Цель	Статус	Комментарий
Full query end-to-end	< 2 мин	N/A / не измерено	Нет сценариев S5+S8 в MVP k6
Stage 1 internal response	P95 ≤ 60 с, P99 ≤ 100 с	N/A	Нет staged registration-check

Требование	Цель	Статус	Комментарий
Stage 2 delivery	SLA $\leq$ 120 с	N/A	Async webhook не в прогоне
Availability	99.5%–99.9%	не подтверждено	Нет soak; Prometheus/Grafana на стенде были down
Deploy on NVIDIA A100	MoSCoW M12	среда не соответствует	Прогон на CPU VPS, не A100

Вывод по бизнесу: релизный Gate 2 по latency полного запроса **не может быть закрыт** этим прогоном. Smoke/baseline подтверждают только работоспособность similarity API, не продуктовый SLA.

3. Соответствие операционным MVP SLO (load_testing_goals §4–§6)

Критерий PASS (§6)	Цель (CPU stand)	Факт	Статус
P1 Error rate S1–S4	< 1% (5xx)	smoke/ baseline 0%; stress 26.8%	FAIL (stress)
P2 Latency P95	$\leq$ 10 с (S1) / $\leq$ 30 с (S2)	mixed stress p95 2.40 с	OK no latency
P3 RPS peak ~7 без деградации §5	~7 RPS, error < 1%	~7.7 iter/s overall, массовые 5xx	FAIL
P4 CPU/RAM не critical (>90%)	< 90%	load avg ~12 после stress; RAM ~3.2 / 3.8 GiB	FAIL / риск
P6 Метрики Grafana/Prometheus	без пробелов	стек мониторинга не поднят	FAIL
P7 Результаты задокументированы	отчёт	этот документ + PDF	OK
Тактический gate	> 95% success under target RPS	stress success ~73%	FAIL

Плановые RPS (§4.4) vs факт

Уровень	План	Факт
Normal mixed	~3 RPS	baseline ~0.8 iter/s при 1 VU (ниже normal; без ошибок)
Peak mixed	~7 RPS	stress overall ~7.7 iter/s, mid (~15 VU) ~10.4 — без SLA по ошибкам

Уровень	План	Факт
Stress max VU	ramp → 30	max VU ~29; на пике throughput падает (~0.8 iter/s) из-за очереди visual

4. Результаты прогонов (k6)

4.1. Сводка

Профиль	Длительность	Итерации	Error rate	Checks	p95 latency	Exit
Smoke	30 с	24	0%	100%	0.80 с	0
Baseline	10 мин	489	0%	100%	0.73 с	0
Stress	20 мин	9247	26.8%	74.6%	2.40 с	99

4.2. Разбивка ошибок backend за окно stress (логи)

Эндпоинт	HTTP 200	502	503
POST /api/v1/text-similarity/search (S1)	5605	0	0
GET /api/v1/health (S4)	850	0	0
POST /api/v1/logo-similarity/search (S2)	107	1578	624
GET /api/v1/logo-similarity/preview (S3)	245	267	0

- S2 success rate ≈ **4.6%** (107 / 2309).
- S1 и S4 — **100%** успех.
- Корневая причина: перегрузка / недоступность visual-model-service (503 busy + 502 через backend).

4.3. Ресурсы хоста (после stress)

- vCPU: 2
- RAM: ~**3.2 GiB used / 3.8 GiB total**
- Load average сразу после: ~**12** (1 / 5 / 15 min: 0.47 / 11.67 / 12.49)

5. Где не соответствуем (подсветка)

1. **Error rate под нагрузкой** — главный gap к §6 P1 и tactical >95%: при ramp 5→30 VU visual отдаёт 502/503; mixed error **26.8%** при цели <**1%**.
2. **Ёмкость с logo в mix** — плановый peak ~7 RPS достигим по throughput, но **не с SLA по ошибкам** (§6 P3).
3. **Продуктовые SLA T3** — не валидированы (нет full query / Stage 1–2).

4. **Наблюдаемость (P6)** — нет time-series CPU/RAM/RPS из Prometheus за прогон.
 5. **Целевое железо A100** — бизнес предполагает GPU; CPU-стенд занижает capacity visual и не закрывает MoSCoW M12 как среду приёма.
-

6. Анализ: что нужно исправить

Приоритет 1 — разблокировать peak с error < 1%

1. Ограничить concurrency visual-model-service (очередь / semaphore / worker pool); отдавать осмысленный **503** и сделать retry/backoff на backend.
2. Исключить reload embeddings / рестарт engine mid-load (в логах stress наблюдалась перезагрузка модели).
3. Вынести visual на больший CPU/GPU или отдельный инстанс; поднять лимиты контейнера (сейчас 2 vCPU / ~4 GiB на весь стек).
4. Повторить профиль **peak** (15 VU / ~7 RPS) и отдельно **S2-only** capacity, пока error rate < 1%.

Приоритет 2 — закрыть gap к бизнесу

1. Поднять Prometheus + Grafana на стенде **до** следующего прогона (критерий P6).
2. После появления S5/S8 добавить E2E timing: full query < 2 мин, Stage 1 P95/P99, Stage 2 ≤ 120 с (Gate 2).
3. Зафиксировать **измеренную** устойчивую ёмкость (макс. RPS при error < 1%) в load_testing_goals.md и на дашборде Load Testing.

Приоритет 3 — процесс

1. Не считать smoke/baseline = соответствие продуктовому SLA.
 2. Документировать каждый прогон по §6 PASS/FAIL (этот отчёт — образец).
 3. Для релизной приёмки планировать прогон на **A100** (MoSCoW M12), не только на CPU VPS.
-

7. Рекомендуемый следующий шаг

1. Починить concurrency/стабильность visual.
 2. Поднять monitoring stack.
 3. Прогон: peak (target ~7 RPS) + S2-only ramp → зафиксировать max RPS при error < 1%.
 4. Обновить цели ёмкости и закрыть issue по capacity.
-

8. Приложения

- Сырые логи k6: smoke.log, baseline.log, stress.log
- Метаданные: meta.txt (smoke_exit=0, baseline_exit=0, stress_exit=99)
- Цели: docs/performance/load_testing_goals.md
- Шаблон: docs/performance/load_test_report_template.md